

*République du Sénégal ■ Un peuple - Un but - Une foi*

# Correction du biais de non-réponse différentiel

Application sur les données de l'Enquête Ménage au Ghana (GLSS)

**Rédigé par :** Thierno BOCOUM | ISEP 2

**Sous la supervision de :** M. Hamady DIALLO

# Plan de la présentation

## Structure

- 01 Introduction & contexte
- 02 Données & préparation
- 03 Simulation du biais MNAR en U
- 04 Diagnostic du biais
- 05 Méthodes de correction
- 06 Analyse comparative & conclusion

## Mots-clés

- ▶ Non-réponse différentielle (MNAR)
- ▶ Modèle logistique quadratique
- ▶ Pondération IPW + régression Firth
- ▶ Imputation hot-deck stratifiée
- ▶ Bornes de Manski
- ▶ Données GLSS (Ghana)

**Objectif global :** Simuler un mécanisme MNAR en U, diagnostiquer le biais engendré sur les dépenses par tête, puis comparer trois méthodes correctives dans un cadre contrôlé et reproductible.

# Contexte et mécanismes de non-réponse

## Problématique

La **non-réponse** est quasi-universelle dans les enquêtes ménages. Le *biais de non-réponse différentiel* survient lorsque la probabilité de ne pas répondre est liée à la **variable d'intérêt elle-même**.

## MNAR en U — Cas étudié

Probabilité de NR **élevée aux deux extrêmes** :

- ▶ Ménages très **pauvres**
- ▶ Ménages très **aisés**

⇒ Biais vers la moyenne + **dispersion sous-estimée**

## Les trois mécanismes classiques

|             |                                                        |
|-------------|--------------------------------------------------------|
| <b>MCAR</b> | Indépendant de tout. Estimateurs sans biais.           |
| <b>MAR</b>  | Lié aux var. observées. Correction possible.           |
| <b>MNAR</b> | Lié à la var. d'intérêt. <b>Cas le plus difficile.</b> |

# Objectifs du rapport

## 01 — Simuler

Un mécanisme MNAR en U contrôlé et reproductible à partir des microdonnées réelles du GLSS (Ghana).

## 02 — Diagnostiquer

Quantifier le biais en comparant répondants et non-répondants sur les covariables et sur la variable d'intérêt (moyenne, médiane, variance).

## 03 — Comparer

Trois méthodes : **IPW (Firth)**, **hot-deck stratifié**, **bornes de Manski**.

## 04 — Recommander

Analyse de sensibilité, limites de chaque approche et recommandations pratiques pour les enquêtes ménages.

# Source des données — Ghana Living Standards Survey

## Contexte du Ghana

- ▶ Population : **33,7 M hab.**
- ▶ PIB/hab. : **3 385 USD**
- ▶ Croissance : **6 %** en 2025
- ▶ Source : GSS

## Format source

Fichier Stata (.dta) importé via le package haven (R). Restriction à 4 variables.

Table 1 — Variables retenues

| Variable      | Description          | Rôle    |
|---------------|----------------------|---------|
| percapita_exp | Dépense par tête     | Intérêt |
| hhsize        | Taille du ménage     | Strat.  |
| urbrur        | Milieu (1=urb/2=rur) | Strat.  |
| age           | Âge chef ménage      | Auxil.  |

# Nettoyage, bootstrap et bruitage


## Pipeline de préparation

1. **Nettoyage** : suppression des NA sur percapita\_exp  
→ **4 621 ménages** (exclusion : 1,7 %)
2. **Bootstrap sans remise** : extension à **5 000 obs.** (379 tirages supplémentaires)
3. **Bruitage gaussien** :  $\sigma_{\text{bruit}} = 5\%$  de l'écart-type, appliqué aux doublons uniquement.

**Fig. 1** : La quasi-superposition des courbes confirme que la distribution des dépenses est **préservée**.

Table 2 — Avant/après bruitage

| Type  | N     | Moy.  | Méd. | Max   |
|-------|-------|-------|------|-------|
| Avant | 4 621 | 137,1 | 92,7 | 595,6 |
| Après | 5 000 | 137,0 | 92,7 | 597,8 |



Source : Enquête ménage Ghana (GLSS), calculs de l'auteur

# Modèle logistique quadratique

$$\text{logit}(\pi_i) = \alpha_0 + \beta_1 z_i + \beta_2 z_i^2 \quad \text{avec } \beta_2 < 0$$


Table 3 — Paramètres de simulation

| Paramètre                              | Valeur          |
|----------------------------------------|-----------------|
| $\beta_1$ (effet linéaire $z_i$ )      | +1,5            |
| $\beta_2$ (effet quadratique $z_i^2$ ) | -2,0            |
| $\alpha_0$ (intercept)                 | calibré         |
| Taux NR cible                          | 34 %            |
| Taux NR réalisé                        | $\approx 34 \%$ |
| Graine (set.seed)                      | 2025            |

## Interprétation

- ▶  $\pi_i$  = probabilité de réponse du ménage  $i$
- ▶  $z_i$  = log-dépense centré-réduit
- ▶  $\beta_2 = -2,0 \Rightarrow$  parabole **concave** (U inversé)
- ▶ Sommet :  $z^* = -\frac{\beta_1}{2\beta_2} = 0,375$  (classe moyenne-sup.)

# Visualisation du mécanisme MNAR en U



**Fig. 2 :** La courbe LOESS en U inversé confirme que les ménages à dépense intermédiaire ont la plus forte probabilité de réponse. Les très pauvres et les très riches se soustraient davantage — taux de NR global : **34 %**.



# Covariables auxiliaires selon le statut de réponse

Tables 4 & 5 — Âge et taille du ménage

| Statut         | Âge moy. | $\sigma$ âge | Taille moy. | $\sigma$ taille |
|----------------|----------|--------------|-------------|-----------------|
| Non-répondants | 48,3     | 15,9         | 4,7         | 2,8             |
| Répondants     | 47,8     | 16,7         | 3,5         | 2,2             |

| Variable      | $t$   | $p$ -value   | Significatif ? |
|---------------|-------|--------------|----------------|
| Taille ménage | 15,13 | $< 10^{-49}$ | OUI            |
| Âge chef      | 1,14  | 0,257        | NON            |

Tables 6 & 7 — Milieu de résidence

| Statut         | Urbain | Rural  |
|----------------|--------|--------|
| Non-répondants | 27,9 % | 72,1 % |
| Répondants     | 40,3 % | 59,7 % |

$$\chi^2 = 74,52, p < 2,2 \times 10^{-18}$$

## Résumé du diagnostic

- ▶ **Âge** : non significatif ( $p = 0,257$ )
- ▶ **Taille ménage** : très sig. ( $p < 10^{-49}$ )  
— liée au milieu rural
- ▶ **Milieu rural** : surreprésenté chez les NR (72 % vs 60 %)

Taille du ménage et milieu rural doivent être inclus dans le **modèle de propension IPW** et dans la **stratification du hot-deck**.

# Impact sur la dépense par tête

Table 8 — Statistiques de la dépense par tête

| Statut         | Moyenne | Médiane | Variance |
|----------------|---------|---------|----------|
| Non-répondants | 136,1   | 43,9    | 28 475   |
| Répondants     | 137,5   | 111,5   | 7 241    |

Table 9 — Tests formels

| Test               | Statistique  | $p$ -value    |
|--------------------|--------------|---------------|
| Student (moyennes) | $t = -0,302$ | 0,762         |
| Kolmogorov-Smirnov | $D = 0,525$  | $< 10^{-269}$ |

## Trois constats clés

1. **Moyenne quasi stable** : compensation des extrêmes — *indicateur trompeur*
2. **Médiane biaisée** : 43,9 (NR) vs 111,5 (R) **(+154 %)**
3. **Variance sous-estimée** : 7 241 vs 28 475 **(-75 %)**

Le test KS ( $p < 10^{-269}$ ) confirme que les deux distributions **diffèrent profondément**. La **médiane** et la **variance** sont les vrais révélateurs du biais MNAR en U.

# Méthode 1 — IPW avec régression de Firth

**Principe :** attribuer à chaque répondant un poids  $w_i = 1/\hat{\pi}_i$  pour compenser sa sous-représentation (Estimateur de Horvitz-Thompson)

Table 10 — Évaluation de la méthode IPW

| Critère               | Évaluation                            |
|-----------------------|---------------------------------------|
| Fondements théoriques | Solides — Horvitz-Thompson            |
| Hypothèse             | MAR cond. aux covariables             |
| Robustesse MNAR       | Partielle (dépend de la spéc.)        |
| Quasi-séparation      | Pénalisation <b>Firth</b> (brglm2)    |
| Poids instables       | Winsorisés au 99 <sup>e</sup> centile |
| Complexité            | Modérée (brglm2+survey)               |

## Covariables du modèle

$z_i, z_i^2$ , milieu de résidence, taille du ménage, âge du chef

La pénalisation de Firth ajoute  $\frac{1}{2} \log \det[\mathcal{I}(\beta)]$  à la log-vraisemblance  $\Rightarrow$  coefficients **stables** même en quasi-séparation parfaite.

## Méthode 2 — Imputation Hot-deck stratifiée

### Principe

Remplacer la valeur manquante d'un NR par celle d'un répondant similaire (**donneur**) tiré **aléatoirement dans la même strate**.

**Strate** = milieu de résidence  $\times$  5 classes de taille de ménage

### Tableau 11 — Évaluation Hot-deck

| Critère      | Évaluation                        |
|--------------|-----------------------------------|
| Hypothèse    | MAR cond. aux strates             |
| Modélisation | Aucune (non paramétrique)         |
| Variance     | <b>Non restaurée aux extrêmes</b> |
| Complexité   | Très faible                       |

### Limite majeure

En MNAR en U, les NR sont aux **extrêmes**. Les donneurs (répondants) sont au **centre**.

⇒ L'imputation réplique des valeurs centrales.

⇒ **Variance non restaurée**.

### Note

À utiliser avec **prudence** : vérifier que les strates contiennent des donneurs aux extrêmes de la distribution.

## Méthode 3 — Bornes de Manski

**Principe** : encadrer la vraie moyenne  $\mu$  *sans aucune hypothèse* sur les non-répondants

### Formule (Manski, 2003)

$$\frac{n_{\mathcal{R}} \bar{y}_{\mathcal{R}} + (n - n_{\mathcal{R}}) y_{\min}}{n} \leq \mu \leq \frac{n_{\mathcal{R}} \bar{y}_{\mathcal{R}} + (n - n_{\mathcal{R}}) y_{\max}}{n} \Rightarrow \underbrace{92,0}_{\text{borne inf.}} \leq \mu \leq \underbrace{294,8}_{\text{borne sup.}} \quad (\text{vraie valeur : } 137,0)$$

Table 12 — Évaluation Manski

| Critère         | Évaluation                  |
|-----------------|-----------------------------|
| Hypothèse       | <b>Aucune</b>               |
| Robustesse MNAR | <b>Totale</b>               |
| Type estimateur | Intervalle seulement        |
| Utilité déc.    | Limitée si intervalle large |
| Complexité      | <b>Très faible</b>          |

Bornes **sharp** : impossibles à resserrer sans hypothèse additionnelle (Manski 2003). L'amplitude de 202,8 traduit l'**incertitude irréductible** liée aux 34 % de NR. À publier **systématiquement**.

# Tableau de synthèse — Comparaison des estimateurs


| Moyenne & Médiane   |              |             |               |
|---------------------|--------------|-------------|---------------|
| Méthode             | Moy.         | Méd.        | $\Delta$ méd. |
| <b>Vraie (réf.)</b> | 137,0        | 92,7        | —             |
| Naïve               | 137,5        | 111,5       | +20,3 %       |
| <b>IPW Firth ★</b>  | <b>136,6</b> | <b>95,0</b> | <b>+2,5 %</b> |
| Hot-deck            | 133,1        | 104,0       | +12 %         |
| Manski inf.         | 92,0         | NA          | —             |
| Manski sup.         | 294,8        | NA          | —             |

| Variance & écart    |               |               |
|---------------------|---------------|---------------|
| Méthode             | Var.          | $\Delta$ var. |
| <b>Vraie (réf.)</b> | 14 494        | —             |
| Naïve               | 7 241         | -50 %         |
| <b>IPW Firth ★</b>  | <b>12 738</b> | <b>-12 %</b>  |
| Hot-deck            | 7 319         | -49 %         |
| Manski inf.         | NA            | —             |
| Manski sup.         | NA            | —             |

★ = meilleure correction    NA = non applicable

**Fig. 3** : L'IPW est la plus proche de la vraie valeur pour tous les indicateurs.

# Graphique comparatif des méthodes



**Lecture :** Chaque groupe de barres correspond à un indicateur (médiane, moyenne, variance). L'IPW (★) est la barre la plus proche de la ligne « Vraie valeur » dans chaque groupe.

# Interprétation des résultats par méthode

## IPW Firth ★ — Meilleure correction

- ▶ Moyenne :  $136,6 \approx 137,0$  (biais  $< 0,3 \%$ )
- ▶ Médiane : 95,0 vs 92,7 (biais  $+2,5 \%$ )
- ▶ Variance :  $12\,738 = 88 \%$  de la vraie valeur

## Hot-deck — Échec sur la dispersion

- ▶ Variance quasi inchangée (7 319 vs naïf 7 241)
- ▶ Médiane sous-corrigée : 104,0 au lieu de 92,7
- ▶ Cause : donneurs concentrés au **centre**

## Naïf — Résultat trompeur

- ▶ Moyenne  $\approx$  vraie valeur — *faux signal*
- ▶ Médiane biaisée :  $+20 \%$  vers le centre
- ▶ Variance réduite de **moitié**

## Bornes de Manski

- ▶ Intervalle  $[92,0; 294,8]$  contient 137,0 ✓
- ▶ Amplitude 202,8 — utilité limitée
- ▶ Approche **la plus honnête** épistémologiquement



# Limites de l'étude

## L1 — Quasi-séparation et IPW

Malgré la pénalisation de Firth, la régression logistique standard **diverge** quand le mécanisme est quasi-déterministe. Toute variation de  $\beta_1, \beta_2$  peut rendre les poids instables.

## L2 — Covariables limitées

Seulement 3 covariables disponibles. Une information plus riche (éducation, profession, région) améliorerait la qualité des corrections.

## L3 — Bruitage contrôlé

Le bruit gaussien modifie très légèrement la distribution. Effet imperceptible sur les indicateurs globaux mais non nul.

## L4 — Validité externe

Simulation calibrée sur une seule enquête (GLSS Ghana). Les résultats illustrent des mécanismes généraux mais ne peuvent être transposés sans précautions.

# Recommandations pratiques

## R1 — Privilégier IPW + Firth

Pour les MNAR fortement liés à la variable d'intérêt, l'IPW avec Firth restaure efficacement moyenne, médiane et variance, même en quasi-séparation.

## R2 — Hot-deck avec prudence

À n'utiliser que si les strates contiennent des donneurs aux extrêmes. Vérifier la couverture préalablement.

## R3 — Publier les bornes de Manski

En complément de tout estimateur ponctuel pour quantifier explicitement l'incertitude irréductible liée au MNAR.

## R4 — Analyses de sensibilité

Faire varier  $\beta_1, \beta_2$ . Envisager l'imputation multiple MICE comme alternative plus robuste au hot-deck simple.

# Conclusion et perspectives

## Principaux enseignements

| Méthode            | Bilan                                    |
|--------------------|------------------------------------------|
| <b>MNAR en U</b>   | Biais fort (méd.+20%, var.-50%)          |
| <b>IPW + Firth</b> | <b>Recommandée</b> : correction optimale |
| <b>Hot-deck</b>    | Inadapté si extrêmes absents             |
| <b>Manski</b>      | Borne [92 ; 295] : incertitude explicite |

## Perspectives

- ▶ Pauvreté multidim.
- ▶ Random Forest
- ▶ Imputation MICE
- ▶ Validation MNAR

Combiner estimateurs ponctuels et bornes d'identification est une bonne pratique.

**Merci de votre attention**

**Questions ?**

---

**Thierno BOCOUM**

ENSAE Pierre Ndiaye / ANSD