



République du Sénégal
Un peuple – Un but – Une foi



Agence nationale de la statistique et de la démographie



École nationale de la statistique et de l'analyse économique
Pierre Ndiaye

Correction du biais de non-réponse différentiel

Application sur les données de l'Enquête Ménage au Ghana (GLSS)

Thème 13 Niveau : ISEP 2

Rédigé par :

Thierno BOCOUM

Élève Ingénieur Statisticien Économiste
(ISEP 2)

Sous la supervision de :

M. Hamady DIALLO

Ingénieur Statisticien Économiste

Année académique 2025–2026

Contents

Décharge	3
Remerciements	4
Résumé	5
1 Définitions des concepts clés	5
2 Introduction	1
2.1 Contexte et problématique	1
2.2 Objectifs	1
2.3 Plan du rapport	1
3 Données et préparation	1
3.1 Présentation du Ghana et de l'enquête	1
3.2 Source des données	2
3.3 Nettoyage des données	2
3.4 Bootstrap contrôlé et bruitage	2
4 Simulation du biais MNAR en U	3
4.1 Modèle logistique quadratique	3
4.2 Paramètres du modèle	4
4.3 Visualisation du mécanisme	4
5 Diagnostic du biais : comparaison répondants / non-répondants sur les auxiliaires (<i>Vérification de la simulation</i>)	4
5.1 Âge et taille du ménage	5
5.2 Milieu de résidence	5
5.3 Dépense par tête	5
5.4 Résumé du diagnostique	6
6 Méthodes de correction du biais	6
6.1 Pondération IPW (<i>Inverse Probability Weighting</i>)	6
6.1.1 Principe	6
6.1.2 Avantages et inconvénients	7
6.2 Imputation hot-deck stratifiée	7
6.2.1 Principe	7
6.2.2 Avantages et inconvénients	7
6.3 Bornes de Manski	7
6.3.1 Principe	7
6.3.2 Avantages et inconvénients	8

7	Analyse de sensibilité comparative	8
7.1	Tableau de synthèse	8
7.2	Graphique comparatif	8
7.3	Interprétation	9
7.4	Limites	9
7.5	Recommandations	10
8	Conclusion	10
	Références	11
	Annexes	12
	Annexe A : Architecture du pipeline R	12
	Annexe B : Méthode de Firth — Détail technique	12
	Annexe C : Bornes de Manski — Démonstration	12

List of Figures

1	Distribution des dépenses par tête avant et après bruitage (axe en log). La quasi-superposition des deux courbes atteste que le bruitage n'affecte pas la distribution.	3
2	Probabilité de réponse simulée en fonction de la dépense par tête (axe en log). La courbe lissée (LOESS) matérialise la forme en U inversé du mécanisme MNAR. Taux de non-réponse global : 34 %.	4
3	Estimations de la dépense moyenne par tête selon la méthode. Plus la barre est proche de la ligne bleu foncé (vraie valeur), meilleure est la correction du biais.	9

List of Tables

1	Variables retenues et leur rôle dans l'analyse	2
2	Statistiques descriptives de la dépense par tête avant et après bruitage	3
3	Paramètres du modèle de simulation MNAR en U	4
4	Statistiques descriptives de l'âge et de la taille du ménage selon le statut de réponse	5
5	Tests de Student de comparaison des moyennes selon le statut de réponse	5
6	Répartition par milieu de résidence selon le statut de réponse (en %)	5
7	Test d'indépendance du χ^2 pour le milieu de résidence	5
8	Statistiques de la dépense par tête selon le statut de réponse	6
9	Diagnostics d'impact de la non-réponse sur la dépense par tête	6
10	Évaluation de la méthode IPW	7
11	Évaluation de l'imputation hot-deck stratifiée	7
12	Évaluation des bornes de Manski	8
13	Comparaison des estimateurs de la dépense par tête selon la méthode de correction. NA = non applicable (les bornes de Manski produisent un intervalle).	8
14	Description des scripts du pipeline d'analyse	12

Décharge

L'École nationale de la statistique et de l'analyse économique Pierre Ndiaye (ENSAE) et l'Agence nationale de la statistique et de la démographie (ANSD) n'entendent donner aucune approbation, ni improbation aux idées émises dans ce présent rapport. Elles sont propres à l'auteur et doivent être considérées comme telles.

Remerciements

Je remercie chaleureusement M. Hamady Diallo, notre professeur du module traitement statistique avec R, pour la confiance qu'il m'a accordée en me confiant ce travail. Malgré sa complexité, ce sujet passionnant m'a offert l'opportunité d'explorer un problème stimulant, d'enrichir mes connaissances et de mettre pleinement à profit mes acquis, en particulier en mathématiques, pour mener à bien ce document.

Résumé

Ce rapport est produit dans le cadre du cours de **Traitements Statistiques avec R** dispensé à l'ENSAE Pierre Ndiaye (ISEP 2, année académique 2025–2026). Il porte sur le **Thème 13** consacré au biais de non-réponse différentiel. À partir des données de l'enquête ménage du **Ghana** (*Ghana Living Standards Survey*) portant sur les dépenses de consommation par tête, nous simulons un mécanisme de non-réponse de type **MNAR en U** (*Missing Not At Random*) via un modèle logistique quadratique calibré pour atteindre un taux de non-réponse de 34 %. Trois méthodes correctives sont ensuite comparées dans le cadre d'une analyse de sensibilité rigoureuse : la pondération par l'inverse de la probabilité de réponse (**IPW**) avec régression de Firth, l'imputation **hot-deck** stratifiée, et les **bornes de Manski**.

Mots-clés : non-réponse différentielle, MNAR en U, régression logistique de Firth, IPW, imputation hot-deck, bornes de Manski, enquête ménage, séparation quasi-parfaite.

1. Définitions des concepts clés

Non-réponse : Absence d'information pour une ou plusieurs variables auprès d'une unité échantillonnée. Elle est dite *totale* si l'unité ne participe pas du tout à l'enquête, *partielle* si certaines questions seulement restent sans réponse.

MNAR en U : Mécanisme de non-réponse où la probabilité de non-réponse est particulièrement élevée aux deux extrémités de la distribution de la variable d'intérêt — les ménages très pauvres *et* très aisés tendent à ne pas répondre, créant un biais vers la moyenne.

Régression logistique : Modèle statistique exprimant la probabilité d'un événement binaire $Y \in \{0, 1\}$ en fonction de covariables $\mathbf{x}$ via la fonction logistique :

$$\Pr(Y = 1 \mid \mathbf{x}) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p)}}$$

ce qui équivaut à modéliser le **log-odds** (logit) par une combinaison linéaire :

$$\text{logit}(\Pr(Y = 1 \mid \mathbf{x})) = \log \frac{p}{1-p} = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$$

Dans notre contexte, $Y = R_i$ (répondre ou non) et le prédicteur inclut un terme quadratique $\beta_2 z_i^2$ pour capturer la forme en U du mécanisme MNAR :

$$\text{logit}(\pi_i) = \alpha_0 + \beta_1 z_i + \beta_2 z_i^2, \quad \beta_2 < 0$$

Séparation quasi-parfaite : Problème qui survient en régression logistique lorsqu'une variable explicative (ou une combinaison de variables) permet de prédire presque parfaitement si un individu appartient au groupe $Y = 1$ ou $Y = 0$. Dans ce cas, l'algorithme d'estimation cherche des coefficients de plus en plus grands pour maximiser la vraisemblance, sans jamais converger :

$$\hat{\beta} \rightarrow \pm\infty \quad \Rightarrow \quad \hat{p}_i = \frac{1}{1 + e^{-\hat{\beta}x_i}} \rightarrow 0 \text{ ou } 1$$

La vraisemblance pénalisée de **Firth** (1993) résout ce problème en ajoutant une pénalité à la fonction à maximiser :

$$\ell_F(\beta) = \ell(\beta) + \frac{1}{2} \log \det[\mathcal{J}(\beta)]$$

où $\mathcal{I}(\beta)$ est la matrice d'information de Fisher. Cette pénalité agit comme un frein naturel qui empêche les coefficients de diverger, tout en produisant des estimations légèrement biaisées mais stables et finies. Dans R, elle est disponible via le package `brglm2`.

IPW : Pondération des répondants par l'inverse de leur probabilité de réponse estimée, pour rétablir la représentativité de l'échantillon observé.

Hot-deck : Imputation par substitution : la valeur manquante d'un non-répondant est remplacée par celle d'un répondant similaire (le "donneur"), tiré dans la même strate.

Bornes de Manski : Intervalle encadrant la vraie valeur moyenne d'une variable dans une population, lorsqu'une partie des données est manquante, sans faire aucune hypothèse sur les individus non observés. Plus le taux de non-réponse est élevé, plus cet intervalle est large — ce qui traduit honnêtement le niveau d'incertitude réelle sur la valeur cherchée.

2. Introduction

2.1. Contexte et problématique

La non-réponse est un phénomène quasi-universel dans les enquêtes statistiques. Elle désigne le fait que certaines unités sélectionnées dans l'échantillon ne fournissent pas les informations requises. Selon la nature du lien entre le fait de ne pas répondre et la variable d'intérêt, la littérature distingue trois mécanismes :

- **MCAR** (*Missing Completely At Random*) : la non-réponse est indépendante de toutes les variables. Les estimateurs classiques restent sans biais ;
- **MAR** (*Missing At Random*) : la non-réponse dépend de variables observées, mais pas de la variable d'intérêt elle-même. Une correction par modélisation est possible ;
- **MNAR** (*Missing Not At Random*) : la non-réponse dépend de la variable d'intérêt elle-même, même conditionnellement aux variables observées. C'est le cas le plus préoccupant.

Le **bias de non-réponse différentiel** désigne la situation MNAR où la probabilité de répondre varie systématiquement selon la valeur de la variable à estimer. Dans les enquêtes sur les revenus et les dépenses des ménages, ce phénomène se manifeste souvent sous une **forme en U** : les ménages aux deux extrêmes de la distribution — très pauvres et très aisés — sont les plus récalcitrants à participer, ce qui écrase artificiellement la dispersion estimée et tire la moyenne vers le centre de la distribution.

2.2. Objectifs

Ce rapport vise à :

1. **Simuler** de façon contrôlée et reproductible un mécanisme MNAR en U à partir de données d'enquête réelles sur les dépenses par tête ;
2. **Diagnostiquer et quantifier** le biais induit par la non-réponse, en comparant les caractéristiques des répondants et des non-répondants sur les variables auxiliaires et sur la variable d'intérêt (moyenne, médiane, variance) ;
3. **Comparer** trois méthodes correctives (IPW, hot-deck, bornes de Manski) selon leur capacité à réduire le biais et leur robustesse aux hypothèses sous-jacentes ;
4. **Conduire** une analyse de sensibilité formelle, montrer les limites de chaque méthode de correction et formuler des recommandations pratiques.

2.3. Plan du rapport

La section 2 présente la source des données, une présentation du Ghana et la procédure de préparation. La section 3 détaille la simulation du mécanisme MNAR en U. La section 4 expose les trois méthodes de correction. La section 5 présente l'analyse comparative. Les sections 6 et 7 concluent par les limites, recommandations et synthèse.

3. Données et préparation

3.1. Présentation du Ghana et de l'enquête

Situé en Afrique de l'Ouest, le Ghana est un pays à revenu intermédiaire dont la croissance économique soutenue s'accompagne de profondes mutations sociales. Avec une population estimée à 33,7 millions d'habitants en 2025 selon les projections officielles du Ghana Statistical Service (GSS, 2024), le pays a connu une progression significative de son niveau de vie. Le Produit Intérieur Brut (PIB) par habitant a

ainsi atteint 3 385 dollars US en 2025, en hausse de 33,9 % par rapport à 2024, porté par une croissance économique de 6 % sur l'année (GSS, 2026).

Le Ghana Living Standards Survey (GLSS), conduit périodiquement par le Ghana Statistical Service, constitue l'enquête de référence pour le suivi des conditions de vie des ménages. Les données de consommation par tête qui en sont issues offrent un indicateur privilégié du niveau de vie et permettent d'appréhender les inégalités et la vulnérabilité des populations.

Dans ce rapport, nous exploitons les microdonnées du GLSS pour simuler un biais de non-réponse différentiel puis évaluer plusieurs méthodes de correction.

3.2. Source des données

Les microdonnées exploitées dans ce travail sont extraites de la dernière vague du **Ghana Living Standards Survey (GLSS)**, l'enquête nationale de référence sur les conditions de vie des ménages ghanéens. Le fichier original, fourni au format Stata (.dta), a été restreint à quatre variables jugées pertinentes pour la simulation du mécanisme MNAR.

Table 1: Variables retenues et leur rôle dans l'analyse

Variable	Description	Type	Rôle
percapita_exp	Dépense par tête – proxy du niveau de vie	Continue	Variable d'intérêt principale
hhsize	Taille du ménage (nombre de personnes)	Entière	Covariable de stratification
urbrur	Milieu de résidence (1 = urbain ; 2 = rural)	Binaire	Covariable de stratification
age	Âge du chef de ménage (années révolues)	Continue	Covariable auxiliaire

Source : Enquête ménage Ghana (GLSS)

3.3. Nettoyage des données


Après importation, les 5000 ménages de l'échantillon final ont été obtenus en deux étapes :

1. Suppression des observations avec valeur manquante sur **percapita_exp** : le jeu de données brut est réduit à **4 621 ménages** exploitables (taux d'exclusion : 1,7 %) ;
2. Extension à **5 000 observations** par bootstrap contrôlé (détaillé ci-après).

3.4. Bootstrap contrôlé et bruitage

Pour renforcer la puissance des simulations, l'échantillon a été étendu à 5 000 observations par bootstrap sans remise : 379 observations supplémentaires ont été tirées parmi les 4 621 ménages d'origine, de sorte qu'aucun ménage n'apparaisse plus de deux fois.

Pour éviter les doublons exacts — qui perturberaient l'estimation des probabilités de réponse — un bruit gaussien d'amplitude $\sigma_{\text{bruit}} = 5\%$ de l'écart-type de chaque variable continue a été ajouté *uniquement* aux doublons sur **percapita_exp**, **hhsize** et **age**. La figure 1 ci-dessous confirme que ce bruitage n'altère pas la distribution empirique des dépenses.



Source : Enquête ménage Ghana (GLSS), calculs de l'auteur

Figure 1: Distribution des dépenses par tête avant et après bruitage (axe en log). La quasi-superposition des deux courbes atteste que le bruitage n'affecte pas la distribution.

Ce tableau compare les principales caractéristiques de la dépense par tête avant et après l'opération de bootstrap contrôlé avec bruitage. Les effectifs passent de 4621 à 5000, mais tous les indicateurs de position (moyenne, médiane, quartiles) et de dispersion (écart-type, extrêmes) demeurent quasiment identiques. Cela confirme que le bruitage gaussien n'altère pas la distribution et que l'échantillon final peut être utilisé pour la simulation du biais de non-réponse sans introduire de perturbation parasite.

Table 2: Statistiques descriptives de la dépense par tête avant et après bruitage

Type	Effectif	Moyenne	Écart-type	Min	Q1	Médiane	Q3	Max
Avant bruitage	4621	137.1	120.5	14.8	51.3	92.7	180.5	595.6
Après bruitage	5000	137.0	120.4	4.5	51.3	92.7	180.2	597.8

Source : Enquête ménage Ghana (GLSS), calculs de l'auteur

4. Simulation du biais MNAR en U

4.1. Modèle logistique quadratique

La simulation repose sur un modèle logistique dont le prédicteur linéaire est une **fonction quadratique** du log-revenu centré-réduit z_i :

$$\text{logit}(\pi_i) = \alpha_0 + \beta_1 z_i + \beta_2 z_i^2$$

où π_i désigne la probabilité que le ménage (i réponde $R_i = 1$, et z_i est son log-revenu centré-réduit. Un coefficient β_2 négatif confère à la probabilité une forme en cloche (U inversé) : la probabilité de réponse est maximale pour les ménages dont le score $f(z_i) = \alpha_0 + \beta_1 z_i + \beta_2 z_i^2$ est le plus élevé. Comme la fonction logistique est monotone croissante, le maximum de π_i coïncide avec celui de f . Avec $\beta_2 = -2,0 < 0$, la parabole est concave et son sommet est atteint en :

$$z_i^* = -\frac{\beta_1}{2\beta_2} = -\frac{1,5}{2 \times (-2,0)} = 0,375$$

Ce résultat indique que le pic de propension à répondre ne se situe pas exactement à la moyenne du log-revenu centré $z_i = 0$, mais légèrement au-dessus, en direction des ménages de la classe moyenne-supérieure. L'intercept (α_0) est calibré numériquement par **uniroot** pour atteindre un **taux de non-réponse global de 34 %**. Le statut $R_i \sim \text{Bernoulli}(\pi_i)$ est tiré indépendamment pour chaque ménage (graine : 2025).

4.2. Paramètres du modèle

Table 3: Paramètres du modèle de simulation MNAR en U

Paramètre	Valeur
beta_1 (effet linéaire de z_i)	+1,5
beta_2 (effet quadratique de z_i^2)	-2,0
alpha_0 (intercept)	calibré par uniroot
Taux de non-réponse cible	34 %
Taux de non-réponse réalisé	~34 %
Graine aléatoire (set.seed)	2025

Source : Calculs de l'auteur

4.3. Visualisation du mécanisme

La figure 2 illustre la relation entre dépense par tête et probabilité de réponse simulée. La forme en U inversé est nettement visible : les ménages à revenu intermédiaire répondent le plus volontiers, ceux aux deux extrêmes s'y soustraient davantage.




Figure 2: Probabilité de réponse simulée en fonction de la dépense par tête (axe en log). La courbe lissée (LOESS) matérialise la forme en U inversé du mécanisme MNAR. Taux de non-réponse global : 34 %.

5. Diagnostic du biais : comparaison répondants / non-répondants sur les auxiliaires (*Vérification de la simulation*)

Cette section compare les caractéristiques des répondants et des non-répondants sur les variables auxiliaires (âge, taille du ménage, milieu de résidence) et sur la variable d'intérêt (dépense par tête). L'objectif est de vérifier que le mécanisme MNAR en U a bien produit un biais conforme aux attentes.

5.1. Âge et taille du ménage

Table 4: Statistiques descriptives de l'âge et de la taille du ménage selon le statut de réponse

Statut	Âge moyen	Écart-type âge	Taille moyenne	Écart-type taille
Non-répondants	48.3	15.9	4.7	2.8
Répondants	47.8	16.7	3.5	2.2

Source : Enquête ménage Ghana (GLSS), calculs de l'auteur

Table 5: Tests de Student de comparaison des moyennes selon le statut de réponse

Variable	Statistique t	Degrés de liberté	P-value	Borne Inf (IC)	Borne Sup (IC)
Taille du ménage (hhsize)	15.134	2813.880	8.36e-50	1.021	1.324
Âge du chef de ménage (age)	1.135	3601.483	0.257	-0.399	1.494

Source : Enquête ménage Ghana (GLSS), calculs de l'auteur

L'âge moyen des chefs de ménage est pratiquement identique dans les deux groupes (48,3 ans pour les non-répondants contre 47,8 ans pour les répondants), et le test de Student confirme l'absence d'écart significatif ($p = 0,257$). En revanche, la taille moyenne du ménage est plus élevée chez les non-répondants (4,7 contre 3,5 personnes), une différence hautement significative ($p < 0,001$). Cette association s'explique par la corrélation entre la taille du ménage et le milieu rural, ce dernier étant lui-même lié à la probabilité de réponse.

5.2. Milieu de résidence

Table 6: Répartition par milieu de résidence selon le statut de réponse (en %)

Statut	Milieu	Effectif	Pourcentage
Non-répondants	Urbain	476	27.9
Non-répondants	Rural	1232	72.1
Répondants	Urbain	1325	40.3
Répondants	Rural	1965	59.7

Source : Enquête ménage Ghana (GLSS), calculs de l'auteur

Table 7: Test d'indépendance du χ^2 pour le milieu de résidence

Statistique du χ^2	Degrés de liberté	P-value
74.521	1	6.00e-18

Source : Enquête ménage Ghana (GLSS), calculs de l'auteur

Les non-répondants résident bien plus souvent en zone rurale (72,1 %) que les répondants (59,7 %). Le test du khi-deux est très significatif ($p < 2,2 \cdot 10^{-1}$). Ce résultat est cohérent avec le modèle de réponse simulé, qui intégrait un effet négatif du milieu rural sur la probabilité de répondre.

5.3. Dépense par tête

Table 8: Statistiques de la dépense par tête selon le statut de réponse

Statut	Moyenne	Médiane	Variance
Non-répondants	136.1	43.9	28475.3
Répondants	137.5	111.5	7241.0

Source : Enquête ménage Ghana (GLSS), calculs de l’auteur

Table 9: Diagnostics d’impact de la non-réponse sur la dépense par tête

Type de Test statistique	Valeur de la statistique	P-value
Test de Student (Comparaison des moyennes)	t = -0.302	0.762
Test de Kolmogorov-Smirnov (Comparaison des distributions)	D = 0.525	2.72e-269

Source : Enquête ménage Ghana (GLSS), calculs de l’auteur

La moyenne des dépenses est très proche entre les deux groupes (136,1 contre 137,5 FCFA), ce qui s’explique par la compensation entre les deux extrêmes du U. En revanche, la médiane des non-répondants est nettement plus basse (43,9 contre 111,5) et leur variance est près de quatre fois plus élevée (28 475 contre 7 241). Le test de Kolmogorov-Smirnov confirme que les deux distributions sont significativement différentes ($p < 2,2 \cdot 10^{-1}$). Ces écarts reflètent bien le mécanisme MNAR en U : les très pauvres et les très riches sont sous-représentés parmi les répondants, ce qui réduit la dispersion observée tout en maintenant une moyenne comparable.

5.4. Résumé du diagnostic

En résumé, le diagnostic met en évidence trois résultats majeurs. Premièrement, l’âge du chef de ménage ne présente aucun lien significatif avec la réponse ($p = 0,257$), ce qui est attendu puisqu’il n’a pas été inclus dans le mécanisme de non-réponse simulé. Deuxièmement, le milieu de résidence est fortement associé au statut de réponse ($p < 0,001$) : les ménages ruraux sont nettement surreprésentés parmi les non-répondants. La taille du ménage suit la même tendance, en raison de sa corrélation avec le milieu rural. Enfin, la dépense par tête, bien que stable en moyenne, voit sa distribution profondément affectée par la non-réponse : la médiane chute et la variance est fortement réduite chez les répondants ($p < 0,001$ au test de Kolmogorov-Smirnov). Ces écarts confirment le caractère MNAR du mécanisme et la nécessité de recourir à des méthodes de correction adaptées.

6. Méthodes de correction du biais

Face au biais de non-réponse différentiel simulé et vérifié sa cohérence, trois familles de méthodes correctives sont comparées, présentées selon le même plan : principe théorique, avantages et inconvénients.

6.1. Pondération IPW (*Inverse Probability Weighting*)

6.1.1. Principe

La méthode IPW compense la sous-représentation des groupes à faible probabilité de réponse en attribuant à chaque répondant un poids inversement proportionnel à sa probabilité estimée de répondre :

$$w_i = \frac{1}{\hat{\pi}_i}, \quad i \in \mathcal{R}$$

Le modèle de réponse inclut z_i , z_i^2 , le milieu de résidence, la taille du ménage et l’âge du chef de ménage. La **méthode de Firth** (`brglm2`) est utilisée pour contourner le problème de séparation quasi-parfaite. Les poids sont ensuite **winsorisés au 99^e centile** pour limiter l’influence des valeurs extrêmes.

6.1.2. Avantages et inconvénients

Table 10: Évaluation de la méthode IPW

Critère	Évaluation
Fondements théoriques	Solides (théorie des sondages, Horvitz-Thompson)
Hypothèse requise	MAR conditionnelle aux covariables du modèle
Robustesse au MNAR	Partielle — dépend de la spécification du modèle
Variance élevée possible	Oui, si certains poids sont extrêmes
Complexité d'implémentation	Modérée (packages brglm2 et survey requis)

Source : simulations de l'auteur

6.2. Imputation hot-deck stratifiée

6.2.1. Principe

L'imputation hot-deck remplace la valeur manquante d'un non-répondant par celle d'un répondant similaire (le « donneur »). La stratification croise le milieu de résidence (**urbrur**) et cinq classes de taille de ménage (**hhsiz**), formant des cellules homogènes. Le donneur est tiré aléatoirement dans la même cellule que le non-répondant.

Cette approche ne nécessite aucune modélisation de π_i et préserve la distribution empirique dans chaque strate.

6.2.2. Avantages et inconvénients

Table 11: Évaluation de l'imputation hot-deck stratifiée

Critère	Évaluation
Hypothèse requise	MAR conditionnelle aux variables de stratification
Modélisation de la réponse	Aucune (méthode non paramétrique)
Propagation de l'incertitude	Non propagée — sous-estimation de la variance
Sensibilité aux strates	Élevée si les strates sont peu informatives
Complexité d'implémentation	Faible

Source : recherche de l'auteur

6.3. Bornes de Manski

6.3.1. Principe

L'approche de Manski (2003) dérive des **bornes d'identification** encadrant la vraie moyenne μ sans aucune hypothèse sur le comportement des non-répondants. En notant n l'effectif total, $n_{\mathcal{R}}$ le nombre de répondants, $\bar{y}_{\mathcal{R}}$ leur moyenne et $[y_{\min}, y_{\max}]$ les bornes observées de la variable :

$$\underbrace{\frac{n_{\mathcal{R}} \bar{y}_{\mathcal{R}} + (n - n_{\mathcal{R}}) y_{\min}}{n}}_{\text{borne inférieure}} \leq \mu \leq \underbrace{\frac{n_{\mathcal{R}} \bar{y}_{\mathcal{R}} + (n - n_{\mathcal{R}}) y_{\max}}{n}}_{\text{borne supérieure}}$$

Ces bornes sont *sharp* : elles ne peuvent être resserrées sans hypothèse additionnelle.

6.3.2. Avantages et inconvénients

Table 12: Évaluation des bornes de Manski

Critère	Évaluation
Hypothèse requise	Aucune
Robustesse au MNAR	Totale
Type d'estimateur	Intervalle — pas de valeur ponctuelle
Utilité décisionnelle	Limitée si l'intervalle est très large
Complexité d'implémentation	Très faible

Source : recherche de l'auteur

7. Analyse de sensibilité comparative

7.1. Tableau de synthèse

Après avoir exposé le principe et les propriétés de chaque méthode corrective, nous appliquons maintenant ces trois approches à notre échantillon simulé et comparons leurs performances sur les indicateurs de position et de dispersion. Le tableau ci-dessous présente les estimations de la moyenne, de la médiane et de la variance pour chaque méthode. La ligne **Vraie** (statistiques sur la population complète, avant non-réponse) constitue la référence absolue. La ligne *Naïve* correspond au calcul brut sur les seuls répondants, sans aucune correction.

Table 13: Comparaison des estimateurs de la dépense par tête selon la méthode de correction. NA = non applicable (les bornes de Manski produisent un intervalle).

Méthode	Moyenne (FCFA)	Médiane (FCFA)	Variance
Vraie	137.0	92.7	14 493.7
<i>Naïve</i>	<i>137.5</i>	<i>111.5</i>	<i>7 241.0</i>
IPW	136.6	95.0	12 737.6
Hot-deck	133.1	104.0	7 319.3
Manski Inf	92.0	NA	NA
Manski Sup	294.8	NA	NA

Source: Enquête ménage Ghana (GLSS), calculs de l'auteur

7.2. Graphique comparatif

La figure 3 compare visuellement les estimations de la dépense moyenne. La ligne bleu foncé en tirets matérialise la vraie valeur de référence. Les bornes de Manski sont exclues de ce graphique du fait de leur nature intervalaire.




Figure 3: Estimations de la dépense moyenne par tête selon la méthode. Plus la barre est proche de la ligne bleu foncé (vraie valeur), meilleure est la correction du biais.

7.3. Interprétation

Estimateur naïf. Comme attendu, il sous-estime fortement la dispersion : la variance chute de 14 494 à 7 241, car les ménages très pauvres et très aisés sont sous-représentés parmi les répondants. La moyenne (137,5) reste proche de la vraie valeur (137,0) par compensation entre les deux extrêmes, mais la médiane (111,5 contre 92,7) révèle un net biais vers le centre de la distribution.

Méthode IPW. Contrairement à ce que laissait craindre l'avertissement de convergence (quasi-séparation), la pondération par l'inverse de la probabilité de réponse, estimée par régression de Firth, corrige de façon très satisfaisante les trois indicateurs. La moyenne IPW (136,6) est quasi identique à la moyenne réelle ; la médiane corrigée (95,0) comble l'essentiel du biais naïf ; la variance remonte à 12 738, soit 88 % de la variance populationnelle. La pénalisation de Firth a donc permis d'obtenir des poids suffisamment stables pour redresser efficacement les queues de distribution, sans être annihilée par la séparation.

Imputation hot-deck. Le hot-deck stratifié ne parvient pas à corriger la variance (7 319, valeur quasi identique à la variance naïve) et ne rapproche la médiane que modestement (104,0). La moyenne est même sous-estimée (133,1). Ce résultat s'explique par la nature du biais en U : les non-répondants se concentrent aux extrêmes de la distribution, alors que les donneurs disponibles dans chaque strate (les répondants) ont des dépenses proches de la moyenne. L'imputation réplique donc mécaniquement des valeurs centrales, sans pouvoir restaurer la dispersion.

Bornes de Manski. L'intervalle [92,0 ; 294,8] contient effectivement la vraie moyenne (137,0). Sa très grande largeur — conséquence directe du taux de non-réponse de 34 % et de l'amplitude des dépenses — illustre l'incertitude maximale en l'absence d'hypothèse. Si l'utilité décisionnelle en est limitée, les bornes de Manski restent l'approche la plus honnête sur le plan épistémologique.

7.4. Limites

1. **Quasi-séparation et IPW.** Bien que l'IPW avec pénalisation de Firth ait fourni une excellente correction, l'avertissement de convergence rappelle que la régression logistique standard échoue lorsque le mécanisme de non-réponse est quasi-déterministe. Une légère variation des paramètres de simulation pourrait rendre les poids instables.

2. **Variables auxiliaires limitées.** Seules trois covariables (milieu, taille du ménage, âge) sont disponibles pour modéliser la probabilité de réponse et stratifier le hot-deck. Une information plus riche (éducation, profession, région) améliorerait la qualité des corrections.
3. **Bruitage contrôlé.** Le bruit gaussien ajouté aux doublons, bien que négligeable, modifie très légèrement la distribution d'origine. Cet effet est imperceptible sur les indicateurs globaux, mais mérite d'être mentionné.
4. **Validité externe.** Les résultats sont issus d'une simulation calibrée sur une seule enquête (Ghana). Ils illustrent des mécanismes généraux, mais ne peuvent être transposés sans précautions à d'autres contextes.

7.5. Recommandations

1. **Privilégier l'IPW avec pénalisation de Firth** lorsque le mécanisme de non-réponse est fortement lié à la variable d'intérêt (MNAR). Notre étude montre que, malgré un avertissement de convergence, l'IPW peut restaurer efficacement la moyenne, la médiane et la variance, à condition d'utiliser une méthode pénalisée robuste.
2. **Utiliser le hot-deck avec prudence lorsque la non-réponse touche les extrêmes.** Le hot-deck ne peut imputer que des valeurs existant chez les répondants. Si les queues de distribution sont vides ou quasi vides parmi les donneurs, l'imputation répliquera des valeurs centrales et ne corrigera pas la dispersion.
3. **Publier systématiquement les bornes de Manski** en complément de tout estimateur ponctuel, pour rendre explicite l'incertitude non identifiable liée au mécanisme MNAR.
4. **Conduire des analyses de sensibilité paramétriques** en faisant varier β_1 et β_2 pour évaluer la robustesse des conclusions à différentes intensités du mécanisme de non-réponse.

8. Conclusion

Ce rapport a étudié, dans un cadre simulé et contrôlé, le biais de non-réponse différentiel engendré par un mécanisme MNAR en forme de U. Les résultats confirment que l'estimateur naïf sous-estime fortement la dispersion et biaise la médiane vers le centre de la distribution, bien que la moyenne puisse rester stable par compensation.

Parmi les trois méthodes de correction comparées, **l'IPW avec régression de Firth** s'est révélée la plus performante : elle a ramené la moyenne, la médiane et la variance très près de leurs vraies valeurs, et ce malgré un problème de quasi-séparation. Le **hot-deck stratifié**, en revanche, n'a corrigé ni la médiane ni la variance, car les strates ne contenaient pas de donneurs situés aux extrêmes de la distribution. Enfin, les **bornes de Manski** ont fourni un encadrement correct de la vraie moyenne, mais avec une largeur qui limite leur utilité opérationnelle.

Ces résultats montrent que le choix de la méthode de correction doit être guidé par la nature du biais suspecté. Lorsque la non-réponse frappe surtout les queues de distribution, l'IPW pénalisé apparaît comme une solution robuste, tandis que le hot-deck peut échouer à restaurer la dispersion. Dans tous les cas, il est essentiel de **combiner** estimateurs ponctuels et bornes d'identification, et d'accompagner toute estimation publiée d'une quantification explicite de l'incertitude irréductible liée au mécanisme MNAR.

Références

Manski, C. F. (2003). *Partial Identification of Probability Distributions*. Springer-Verlag, New York.

Rubin, D. B. (1976). Inference and missing data. *Biometrika*, **63**(3), 581–592.

Seaman, S. R. & White, I. R. (2013). Review of inverse probability weighting for dealing with missing data. *Statistical Methods in Medical Research*, **22**(3), 278–295.

Annexes

Annexe A : Architecture du pipeline R

Table 14: Description des scripts du pipeline d'analyse

Script	Rôle
00_setup.R	Chargement des packages (haven, dplyr, ggplot2, survey, brglm2)
01_import_nettoyage.R	Import du fichier .dta, suppression des NA sur percapita_exp
02_bootstrap_bruitage.R	Extension à 5 000 obs. par bootstrap, bruitage des doublons
03_simulation_biais.R	Modèle logistique quadratique, calibration alpha_0, tirage R_i
04_ipw.R	Régression de Firth, poids winsorisés, estimation via survey
05_hotdeck.R	Imputation hot-deck stratifiée (milieu $\times$ taille du ménage)
06_manski.R	Calcul des bornes d'identification de Manski
07_analyse_sensibilite.R	Tableau comparatif et graphique de synthèse

Source : architecture du projet Thème 13

Annexe B : Méthode de Firth — Détail technique

La régression logistique standard diverge en présence de séparation quasi-parfaite : les coefficients tendent vers $\pm\infty$. La **méthode de Firth** (1993) régularise l'estimation en ajoutant au log-vraisemblance une pénalité de Jeffreys :

$$\ell_F(\beta) = \ell(\beta) + \frac{1}{2} \log \det[\mathcal{I}(\beta)]$$

Cette pénalité maintient les estimations finies même en cas de séparation parfaite. Elle est implémentée dans R via `brglm2` avec l'argument `method = "brglmFit"`.

Annexe C : Bornes de Manski — Démonstration

Soit $\mu = \mathbb{E}[Y]$ la moyenne populationnelle. On décompose :

$$\mu = \frac{n_{\mathcal{R}}}{n} \bar{y}_{\mathcal{R}} + \frac{n - n_{\mathcal{R}}}{n} \mathbb{E}[Y \mid R = 0]$$

Sans aucune hypothèse sur $\mathbb{E}[Y \mid R = 0]$, la seule contrainte identifiable est $y_{\min} \leq \mathbb{E}[Y \mid R = 0] \leq y_{\max}$, ce qui donne immédiatement :

$$\frac{n_{\mathcal{R}} \bar{y}_{\mathcal{R}} + (n - n_{\mathcal{R}}) y_{\min}}{n} \leq \mu \leq \frac{n_{\mathcal{R}} \bar{y}_{\mathcal{R}} + (n - n_{\mathcal{R}}) y_{\max}}{n}$$

Ces bornes sont **sharp** (Manski, 2003, Theorem 1.1) : elles ne peuvent être resserrées sans hypothèse additionnelle sur le comportement des non-répondants.